

BÁO CÁO CUỐI CÙNG

Dự báo lưu lượng giao thông I-94 (chiều westbound) — trạm ATR 301

Project 20 — Bài 7: Rò rỉ dữ liệu, chia tập đúng và đánh giá trung thực

Môn học	Data Mining / Machine Learning (đề tài về rò rỉ dữ liệu & đánh giá trung thực)
Nhóm	Nhóm 20 — xem mục *Nhóm & phân công* ở §17.6 (cần người dùng điền)
Bộ dữ liệu	Metro Interstate Traffic Volume — UCI ML Repository, giấy phép CC BY 4.0
Mô hình	Ridge Regression (L2), $\alpha = 0,001$, solver lsqr
Checkpoint	3.1 — hoàn thiện Web/API + Test + Tài liệu
Trạng thái	Đã chạy thật: 317 test pass, 0 fail; server <code>http://localhost:8000</code> chạy được

Ghi chú về nguồn số liệu. Mọi con số trong báo cáo này được lấy từ artifact do mã nguồn sinh ra: `models/model_metadata.json`, `models/run_config.json`, `models/baseline_meta.json`, `reports/figures/evaluation_results.json`, `reports/figures/experiments_results.json`, `reports/figures/alpha_tuning.json`, `data/processed/data_audit.json`. Không có con số nào được gõ tay. Khi chạy lại pipeline, báo cáo tự cập nhật. **Phân biệt thể loại nội dung** — dùng nhất quán trong toàn bộ báo cáo: - **[BẮT BUỘC]** — yêu cầu trực tiếp từ đề tài / dữ liệu / giảng viên. - **[QUYẾT ĐỊNH]** — lựa chọn của nhóm, được nêu rõ lý do. - **[HẠN CHẾ]** — điều mô hình không làm được hoặc dữ liệu không cho phép.

MỤC LỤC

- Tóm tắt điều hành
- Đặt vấn đề và mục tiêu nghiên cứu
- Dữ liệu và chất lượng dữ liệu
- Tiền xử lý và chống rò rỉ
- Chia tập theo thời gian
- Phân tích khám phá (EDA, chỉ trên TRAIN)
- Baseline và mô hình chính
- Chọn tham số alpha
- Kết quả FINAL TEST 2018
- Phân tích lỗi chi tiết
- Thí nghiệm phát triển (2012–2017)
- Ứng dụng Web / API
- Kiểm thử tự động
- Model Card
- Hạn chế và ngoài phạm vi sử dụng
- Kết luận và hướng mở rộng
- Phụ lục

1. Tóm tắt điều hành

Bài toán: ước lượng **lưu lượng giao thông theo giờ** tại trạm đo ATR 301 trên đường I-94, chiều westbound, chỉ từ thông tin lịch và thời tiết — thông tin **biết trước hoặc quan sát được tại đúng giờ cần dự báo**.

Kết quả chính trên **FINAL TEST 2018** (6.533 giờ, hoàn toàn ngoài mẫu huấn luyện):

Mô hình	MAE (xe/giờ)	RMSE (xe/giờ)	R ²
Baseline: trung bình theo giờ × thứ	272,90	473,13	0,9426

Mô hình	MAE (xe/giờ)	RMSE (xe/giờ)	R ²
Ridge pipeline (alpha = 0,001)	259,73	416,78	0,9554
Cải thiện	-13,17 (-4,8 %)	-56,35 (-11,9 %)	+0,0128

Ba kết luận quan trọng nhất:

• **Mô hình vượt baseline trên cùng một tập kiểm định.** Cả hai mô hình được đánh giá trên

đúng một tập dữ liệu 2018, đều fit trên *đúng một tập* 2012–2016 → phép so sánh công bằng.

• **Sai số tập trung ở ngày lễ và thời tiết cực đoan.** MAE ngày lễ là 1.031,44 (n = 167) so với

239,49 ở ngày thường; MAE khi có tuyết là 524,50 so với 235,96 khi không có. Đây là giới hạn thật, không phải lỗi mã nguồn.

• **Việc chia tập quyết định kết luận.** Thí nghiệm 1b với ba arm dùng chung một tập test cho thấy

MAE giảm 7,55 chỉ vì đưa dữ liệu sát thời điểm dự báo hơn vào tập huấn luyện — phần giảm đó *không* đến từ năng lực mô hình. Đây là lý do mọi kết luận trong báo cáo này đều dựa trên time split.

Ứng dụng web chạy tại <http://localhost:8000> với 3 màn hình và 4 endpoint; ứng dụng **chỉ nạp artifact đã đóng băng**, không huấn luyện lại, không tinh chỉnh tham số, không fit lại bộ tiền xử lý.

2. Đặt vấn đề và mục tiêu nghiên cứu

2.1 Bối cảnh

Một đơn vị vận hành giao thông muốn có một ước lượng sơ bộ về lưu lượng xe đi qua một trạm đo cố định trước khi có số đo thực tế, để hỗ trợ lập kế hoạch. Dữ liệu lịch sử cho trạm này đã có, nhưng mô hình dự báo phải đáp ứng hai ràng buộc khó nhất:

- chỉ được dùng thông tin **có thật và biết trước tại thời điểm dự báo**;
- kết luận phải **trung thực**, tức không được nhìn tương lai khi đánh giá quá khứ.

[BẮT BUỘC] Bài 7 của đề tập trung vào *data leakage* và *đánh giá trung thực*. Vì vậy phần lớn công sức của nhóm dồn vào thiết kế chia tập, tiền xử lý và bằng chứng — không phải vào việc thử nhiều mô hình phức tạp.

2.2 Câu hỏi nghiên cứu

- Đánh giá ngẫu nhiên (random split) và đánh giá trên tương lai (time split) chênh lệch bao nhiêu, và cái nào là cái đúng?
- Mô hình có vượt được baseline theo lịch (giờ × thứ trong tuần) không?
- Sai số tập trung ở đâu: giờ nào trong ngày, ngày nào trong tuần, ngày lễ, hay thời tiết cực đoan?
- Chất lượng có trôi dạt (drift) theo thời gian không?
- Có thể đưa mô hình ra phục vụ mà không tạo *train-serving skew* không?

2.3 Đơn vị quan sát, đầu vào, đầu ra

Đơn vị quan sát	1 giờ tại trạm đo ATR 301
Biến mục tiêu	traffic_volume — lưu lượng, đơn vị xe/giờ
Loại bài toán	Hồi quy chuỗi thời gian
Đầu vào lúc dự báo	Ngày giờ + nhiệt độ + lượng mưa/tuyết 1 giờ + độ phủ mây + hiện tượng thời tiết
Thời điểm biết được	Tất cả đều là dữ liệu thời tiết quan sát tại giờ đó hoặc lịch công cộng biết trước

3. Dữ liệu và chất lượng dữ liệu

Nguồn: [data/processed/data_audit.json](#) và [reports/figures/data_quality_report.md](#).

3.1 Nguồn và giấy phép

- **Metro Interstate Traffic Volume**, UCI Machine Learning Repository.
- Giấy phép: **CC BY 4.0**. Trích dẫn bắt buộc: Hamed Tabatabaeyan, Meng Lu, et al. (2020).
- Tải bằng `py src\download_data.py`; SHA256 được ghi trong `data/README.md` để xác thực.

3.2 Quy mô

Mốc	Giá trị
Số dòng thô	48.204
Số timestamp duy nhất	40.575
Số nhóm trùng <code>date_time</code>	5.445 (mỗi nhóm 2–6 dòng; 13.074 dòng nằm trong nhóm trùng)
Số dòng loại bởi <code>collapse</code>	7.629
Số dòng dùng để mô hình hoá	40.575
Khoảng thời gian	2012-10-02 09:00:00 → 2018-09-30 23:00:00
Số giờ *vắng mặt*	11.976 (22,79 % so với 52.551 giờ lý thuyết)

[QUYẾT ĐỊNH] Không nội suy (interpolate) các giờ vắng mặt. Một giờ không có quan sát thì không tạo ra quan sát giả; việc thiếu dữ liệu được phản ánh trong mục Hạn chế thay vì che giấu bằng thống kê học từ tập lớn.

3.3 Ba bẫy dữ liệu đã được phát hiện và xử lý

(a) Trùng `date_time` — bẫy lớn nhất

Dataset gốc có 5.445 timestamp xuất hiện 2–6 lần. Mỗi giờ có thể có **nhiều mô tả thời tiết khác nhau** (ví dụ một bản ghi "mưa nhẹ" và một bản ghi "mưa vừa").

[QUYẾT ĐỊNH] Không dùng `drop_duplicates(keep="first")`. Vì:

- `keep="first"` phụ thuộc **thứ tự dòng trong file** → không tắt định, khó tái lập;
- nó **vứt bỏ thông tin thời tiết** của các dòng bị loại.

Cách nhóm xử lý (tắt định, không học thống kê từ dữ liệu):

- phép đo (`traffic_volume`, `temp`, `rain_1h`, `snow_1h`, `clouds_all`): lấy **trung vị**;
- `weather_main`: **multi-hot** — giữ mọi hiện tượng xuất hiện; nhãn đại diện là giá trị xuất hiện nhiều nhất, hoà thì lấy theo thứ tự alphabet;
- `weather_description`: nén 38 chuỗi thô về 11 nhóm gia đình bằng quy tắc keyword, lấy nhóm nghiêm trọng nhất.

Bảng chứng an toàn: `traffic_volume` và `holiday` **bất biến 100 %** trong mọi nhóm trùng ($n = 5.445$). Nghĩa là `collapse` không làm thay đổi mục tiêu ở bất kỳ dòng nào. `weather_main` và `weather_description` biến thiên ở lần lượt 5.349 và 5.386 nhóm — đúng lý do phải `multi-hot` thay vì lấy một dòng.

(b) Giá trị vô lý

Quy tắc	Số dòng	Lý do
<code>temp <= 0, 0 K</code>	10	0 K là nhiệt độ tuyệt đối — quy tắc vật lý , không phải ngưỡng thống kê
<code>rain_1h = 9831,3</code>	1	Khớp chính xác một giá trị sentinel đã audit trong bản phát hành này

[QUYẾT ĐỊNH] Không dùng ngưỡng thống kê (ví dụ "trên 99,9 phân vị là sai"). Một ngưỡng suy ra từ phân bố toàn tập sẽ là học thống kê trên cả `validation` và `test` — tức rò rỉ.

Giá trị thiếu sau đó được `SimpleImputer(median)` điền **bên trong pipeline**, fit trên TRAIN.

(c) Cột `holiday` và bẫy `keep_default_na`

Cột `holiday` chứa chuỗi "None" (không phải ngày lễ), không phải giá trị rỗng. Nếu đọc bằng mặc định của `pandas`, "None" bị hiểu thành NaN và mọi dòng đều trông như ngày lễ.

[QUYẾT ĐỊNH] Đọc bằng `keep_default_na=False`. Audit xác nhận 0 dòng bị hiểu sai.

!Phân bố lưu lượng trên TRAIN

Hình 1 — Phân bố `traffic_volume` trên TRAIN. Nguồn: `src/eda.py`.

Ngoài ra, cột `holiday` gốc **chỉ ghi tên ở giờ 00:00** của ngày lễ. Nếu suy ra cờ ngày lễ bằng cách quét các dòng khác trong cùng ngày thì:

- ở thời điểm dự báo ta chỉ có *một* dòng → không làm được (đó chính là train-serving skew);
- để biết ngày X có lễ hay không, ta đã phải "nhìn" dữ liệu của chính ngày X → rò rỉ.

[QUYẾT ĐỊNH] Xây dựng **lich ngày lễ tất định** trong `src/holidays.py`, tính thuần từ ngày tháng: 10 ngày lễ liên bang theo quy tắc lịch + bảng ngày khai mạc Minnesota State Fair do bang công bố.

Đối chiếu với dataset: lịch khớp **53/53** ngày lễ mà dataset ghi nhận, bỏ sót **0** ngày, không sai tên. Đây là bằng chứng lịch tất định là đúng, không phải giả định.

Lịch ngày lễ là **thông tin công cộng biết trước**: ai cũng biết 4/7 là ngày lễ trước khi nó tới. Vì vậy dùng nó làm feature là hợp lệ, **không phải rò rỉ**.

4. Tiền xử lý và chống rò rỉ

4.1 Nguyên tắc phân loại biến đổi

Loại	Ví dụ	Fit trên	Ảnh hưởng
Quy tắc tất định	°C→K, giờ/thứ/tháng, hour_dow, is_holiday, multi-hot thời tiết, collapse median	—	Không bao giờ gây rò rỉ hay train-serving skew
Thống kê học được	SimpleImputer(median), StandardScaler, OneHotEncoder	TRAIN duy nhất	Phải nằm trong Pipeline

Mọi thống kê học được nằm trong một `sklearn.pipeline.Pipeline` duy nhất, được fit trên tập TRAIN 2012–2016 và transform trên validation/test/serving. `src/train.py` chỉ gọi fit đúng một lần, trên `X_train`.

4.2 Bảy quy tắc chống rò rỉ của nhóm

- Mọi biến đổi trước khi tách tập là **quy tắc tất định**, không học thống kê.
- Imputer/scaler/encoder chỉ fit trên TRAIN.
- Không dùng ngưỡng hậu nghiệm rút ra từ phân bố toàn bộ tập dữ liệu.
- FINAL TEST 2018 không tham gia tuning hay model selection.
- Không interpolate trước khi tách tập.
- `traffic_volume` không bao giờ làm feature.
- Không trộn metric in-sample (train) với out-of-sample (val/test).

Quy tắc 4 được **cưỡng chế bằng mã nguồn**, không chỉ bằng lời hứa: `src/experiments.py` gọi `assert_no_final_test_rows()` ở mọi hàm và sẽ dừng chương trình nếu bất kỳ dòng năm 2018 nào lọt vào (`tests/test_experiments.py` — 15 test bảo vệ điều này).

5. Chia tập theo thời gian

Tập	Khoảng thời gian	Số dòng	Vai trò
TRAIN	2012-10-02 09:00:00 → 2016-12-31 23:00:00	25.329	Fit mô hình, imputer, scaler, encoder, baseline
VALIDATION	2017-01-01 00:00:00 → 2017-12-31 23:00:00	8.713	Chọn alpha
FINAL TEST	2018-01-01 00:00:00 → 2018-09-30 23:00:00	6.533	Chỉ đánh giá

Ba assert được kiểm tra mỗi lần chạy và ghi vào artifact:

- `max(train) < min(validation)` → đúng
- `max(validation) < min(test)` → đúng
- không có timestamp nào chung giữa ba tập → đúng

[QUYẾT ĐỊNH] Dùng **expanding-window time split** thay vì `train_test_split` ngẫu nhiên. Ngẫu nhiên hoá sẽ đưa các giờ của năm 2018 vào tập huấn luyện, khiến mô hình "nhìn thấy" hàng xóm của chính dòng cần dự báo — đây chính là dạng rò rỉ mà đề tài muốn chỉ ra. Mục 11.1 đo lại mức độ lạc quan do random split.

[HẠN CHẾ] FINAL TEST chỉ kéo dài tới **30/09/2018** — không có dữ liệu tháng 10–12/2018. Ba tháng cuối năm (mùa cao điểm thu lượng) không được đánh giá. Mọi kết luận về 2018 áp dụng cho 9 tháng đầu năm.

6. Phân tích khám phá (EDA, chỉ trên TRAIN)

Nguồn: `reports/figures/eda_train_only.md`.

6.1 Phân bố mục tiêu (TRAIN)

Thống kê	Giá trị
Số quan sát	25.329
Min / Max	0 / 7.260
Mean / Std	3.252,51 / 1.987,14
Median	3.339
p05 / p95	336 / 6.199
Số giờ có lưu lượng = 0	2

6.2 Hình dạng theo giờ × thứ — cấu trúc mạnh nhất của bài toán

Lưu lượng trung bình theo giờ và thứ (TRAIN) cho thấy rõ:

- **Hai đỉnh sáng:** ~07:00–08:00 (ngày làm việc) và ~16:00–17:00;
- **Đáy ban đêm** 02:00–03:00 (khoảng 280–400 xe/giờ ngày làm việc);
- **Cuối tuần hoàn toàn khác hình dạng:** thứ Bảy–Chủ nhật đường cong phẳng, đỉnh dịch sang khoảng 15:00–17:00 và cao hơn nhiều vào ban đêm (ví dụ 00:00 Chủ nhật 1.335 so với 617 thứ Hai).

!Lưu lượng trung bình theo giờ và thứ trong tuần

Hình 2 — Lưu lượng trung bình theo giờ × thứ, TRAIN. Nguồn: `src/eda.py`. Hai đỉnh sáng và chiều, và hình dạng cuối tuần khác hẳn ngày làm việc, đều thấy rõ ở đây.

Đây chính là cấu trúc mà **baseline khai thác** và là lý do `hour_dow` (tương tác giờ × thứ) là feature chính của mô hình.

6.3 Ảnh hưởng của tháng và ngày lễ

- Trung bình theo tháng nằm trong khoảng ~2.800–3.800, thấp nhất ở tháng 12 và 1, cao hơn vào tháng 6–8. **[QUYẾT ĐỊNH]** đưa `month` vào nhóm categorical. !Lưu lượng trung bình theo tháng và năm

Hình 3 — Lưu lượng trung bình theo tháng × năm, TRAIN. Nguồn: `src/eda.py`. Các ô trống ở 2012 (chỉ có từ tháng 10) và 2015 (thiếu quý I–II) là do thiếu dữ liệu, không phải do lọc.

- Ngày lễ làm đường cong lưu lượng thay đổi mạnh → cờ `is_holiday` là feature **bắt buộc**.

!Ảnh hưởng của ngày lễ

Hình 4 — Ảnh hưởng của ngày lễ, TRAIN. Nguồn: `src/eda.py`.

7. Baseline và mô hình chính

7.1 Baseline — bắt buộc theo đề

[BẮT BUỘC] Đề yêu cầu so sánh mô hình với một baseline hợp lý.

[QUYẾT ĐỊNH] Baseline là ****trung bình lưu lượng theo giờ × thứ trong tuần, fit chỉ trên TRAIN**** (25.329 dòng), lưu ở `models/baseline_table.csv`. Có `global_fallback = 3.252,51` cho ô trống. Baseline dùng **đúng tập huấn luyện** như Ridge → phép so sánh trên test là công bằng.

Vi sao baseline này mạnh: nó khai thác đúng cấu trúc mạnh nhất đã tìm thấy ở EDA (§6.2), và không dùng thời tiết. Nếu Ridge chỉ bằng hoặc thua baseline thì mô hình không có giá trị.

7.2 Mô hình chính

[QUYẾT ĐỊNH] Chọn **Ridge Regression (L2)** trong `sklearn.pipeline.Pipeline`:

```
ColumnTransformer
├── cat (4 cột) : OneHotEncoder(handle_unknown="ignore", sparse_output=False)
├── num (5 cột) : SimpleImputer(strategy="median") → StandardScaler()
└── bin (12 cột) : passthrough
↓
Ridge(alpha, solver="lsqr")
```

Vì sao Ridge: đề tài thiên về minh họa phương pháp đánh giá, không phải sẵn điểm. Ridge tuyến tính, dễ giải thích, chịu được đa cộng tuyến tốt, và cho phép so sánh ý nghĩa từng nhóm feature. Một mô hình phức tạp hơn (gradient boosting) sẽ cho MAE tốt hơn nhưng làm sai lệch trọng tâm của đề bài, và khó trả lời "vì sao".

`solver="lsqr"` vì ma trận sau one-hot khá rộng (217 cột) nhưng mẫu chỉ 25.329; `lsqr` ổn định và nhanh, tránh vấn đề lập ma trận phân rã.

7.2.1 Danh mục feature (217 cột sau tiền xử lý)

Nhóm	Số cột	Tên
Categorical	4	hour_dow, month, weather_main_mode, weather_family
Numeric	5	temp, rain_1h, snow_1h, clouds_all, weather_severity
Binary	12	is_holiday, wm_clear ... wm_thunderstorm (11 cột multi-hot)

Ghi chú thiết kế:

- `hour_dow` = giờ × thứ — đúng độ chi tiết baseline dùng, để Ridge học được cùng effect đó

cộng thêm thời tiết và tháng.

- `temp` lưu ở **Kelvin** (nhiệt độ tuyệt đối) vì đó là cách dataset lưu. API nhận **°C** và tự

quy đổi.

- `weather_severity` là thang mức độ **do analyst định nghĩa** (0 quang → 4 giông/bão), dùng để gộp nhiều mô tả thời tiết của cùng một giờ thành một số.

- 11 cột `wm_*` là **multi-hot**: một giờ có thể vừa mưa vừa tuyết vừa giông.

7.2.2 Thống kê imputer/scaler đã học (lưu trong `model_metadata.json`)

Cột	Median (imputer)	Mean (scaler)
temp	282,08	280,9479
rain_1h	0,0	0,1054
snow_1h	0,0	0,0002
clouds_all	40,0	45,433
weather_severity	1,0	1,1751

Đây là **bằng chứng máy đọc được** rằng bộ tiền xử lý đã học trên TRAIN (ví dụ mean `clouds_all` = 45,43 là trung bình của TRAIN, không phải của toàn bộ 48.204 dòng).

8. Chọn tham số alpha

[BẮT BUỘC] Tiêu chí: **MAE trên VALIDATION 2017**. Test 2018 không được mở ra ở bước này.

alpha	MAE (val)	RMSE (val)	R ²
0,001	272,12	421,46	0,9548
0,003	272,13	421,46	0,9548
0,01	272,14	421,46	0,9548
0,03	272,19	421,47	0,9548
0,1	272,35	421,50	0,9548
0,3	272,81	421,59	0,9548
1,0	274,58	422,04	0,9547
3,0	280,77	424,37	0,9542
10,0	312,13	442,39	0,9502
30,0	429,00	539,15	0,9260

alpha	MAE (val)	RMSE (val)	R ²
100,0	751,03	882,70	0,8017
300,0	1.146,97	1.332,33	0,5483
1.000,0	1.461,15	1.688,71	0,2744

Kết quả: $\alpha = 0,001$.

Diễn giải: Ở vùng α nhỏ (0,001–0,3) hiệu năng gần như nhau — dữ liệu không bị quá nhiễu nên hiệu chuẩn không cần mạnh. Từ $\alpha \geq 10$ mô hình bị co quá nặng và MAE tăng vọt. Chọn biên nhỏ nhất là lựa chọn ít giả định nhất, và nó cũng cho MAE tốt nhất trên validation.

MAE trên VALIDATION của Ridge: 272,12 so với **baseline 278,66** — mô hình đã vượt baseline ngay trên tập dùng để chọn tham số. Sự thật này được kiểm tra lại độc lập trên FINAL TEST (§9).

9. Kết quả FINAL TEST 2018

9.1 Bảng kết quả chính

Mô hình	MAE	RMSE	R ²	n
Baseline (giờ × thứ)	272,90	473,13	0,9426	6.533
Ridge pipeline ($\alpha = 0,001$)	259,73	416,78	0,9554	6.533
Cải thiện	−13,17 (−4,8 %)	−56,35 (−11,9 %)	+0,0128	—

[BẮT BUỘC] Đây là kết luận chính thức của báo cáo.

Đây là số của RAW MODEL (Ridge trả về trực tiếp, không hậu xử lý). Tầng phục vụ có thêm một bước chiếu về sản — $\text{DEPLOYED PREDICTOR} = \max(0, \cdot)$ □ Ridge — được báo riêng ở §12.5 và **không** phải cùng một model metric. Nhóm **không** sửa bảng này cho khớp API.

9.2 Vì sao phép so sánh này đáng tin

Điều kiện	Baseline	Ridge
Tập fit	2012–2016 (25.329 dòng)	2012–2016 (25.329 dòng)
Tập đánh giá	2018-01-01 → 2018-09-30 (6.533 dòng)	cùng
Có dùng năm 2018 để lựa chọn không?	Không	Không

Hai mô hình được đánh giá trên **cùng một tập dữ liệu**, được xây trên **cùng một tập huấn luyện**, và **không** mô hình nào được chọn bằng cách nhìn năm 2018.

9.3 So với validation — dấu hiệu tích cực

Tập	MAE	RMSE	R ²	n
VALIDATION 2017 (dùng để chọn α)	272,12	421,46	0,9548	8.713
FINAL TEST 2018	259,73	416,78	0,9554	6.533

MAE và RMSE trên FINAL TEST **thấp hơn** validation, R² cao hơn. Nghĩa là hiệu năng **không suy giảm** khi dữ liệu dài thêm một năm — dấu hiệu mô hình không bị overfit theo thời gian.

Cần thận trọng khi diễn giải: có thể năm 2017 đơn giản hơn 2018, nên chưa thể kết luận "mô hình đang tiến bộ". Đây cũng là kết luận mà thí nghiệm rolling-origin (§11.3) nêu thẳng.

9.4 Tính trung thực khi nói về FINAL TEST 2018

Phát biểu chính xác (dùng nguyên văn trong bảo vệ):

Năm 2018 không tham gia hyperparameter tuning hoặc model selection. Pipeline và serving policy được đóng băng từ dữ liệu 2012–2017. Kết quả 2018 không được dùng để tiếp tục tối ưu mô hình.

Cụ thể hóa từng vế:

- **Không tuning / model selection trên 2018.** Toàn bộ lựa chọn về tiền xử lý, đặc trưng, mô hình và tham số α được chốt trên 2012–2017; α chọn theo MAE trên VALIDATION 2017 (§8).
- **Pipeline được đóng băng trước khi 2018 được mở ra.** Thứ tự chạy bắt buộc là

train → experiments → freeze_serving_policy → evaluate → postprocess_audit (§17.2).

• **Serving policy cũng được đóng băng từ 2012–2017.** `src/freeze_serving_policy.py` chỉ đọc

TRAIN + VALIDATION; `src/postprocess_audit.py` chỉ **đo** hậu quả trên 2018 và **từ chối chạy** nếu policy chưa được đóng băng. Như vậy policy `max(0, ·)` không phải test-informed postprocessing (§12.5).

• **Kết quả 2018 không quay ngược lại điều chỉnh mô hình.** Sau khi đọc số 2018, nhóm không sửa feature, không sửa alpha, không đổi mô hình, và không sửa lại gói đánh giá để khớp API (§12.5.8).

Phát biểu này cố ý **không** khẳng định 2018 chỉ được chạy đúng một lần — nhóm không đưa ra tuyên bố không thể chứng minh. Điều cần chứng minh là **không có vòng lặp tối ưu nào đi qua 2018**, và điều đó đã được củng cố bằng `assert_no_final_test_rows()` trong toàn bộ mã nguồn thí nghiệm phát triển.

10. Phân tích lỗi chi tiết

Nguồn: `reports/figures/evaluation_results.json` → `error_analysis`. Mọi phân khúc đều kèm số mẫu n .

10.1 Theo giờ trong ngày

Giờ	n	MAE Ridge	MAE baseline	Lưu lượng thực TB	Dự báo TB	Bias
00:00	273	176,39	110,72	831	865	+34,30
03:00	270	142,14	31,14	372	408	+36,26
07:00	271	355,75	422,46	4.813	4.811	-2,46
08:00	272	376,07	434,41	4.630	4.610	-20,23
16:00	273	408,80	485,32	5.794	5.678	-115,36
17:00	273	373,38	422,64	5.329	5.350	+20,51
22:00	273	348,61	323,83	2.234	2.214	-19,94

(bảng rút gọn; đầy đủ 24 giờ nằm trong `evaluation_report.md` và trên màn Dashboard)

Độc kết quả:

• MAE lớn nhất rơi vào **16:00 (408,80)** và **08:00 (376,07)** — cũng là hai lúc lưu lượng lớn

nhất. Sai số **tương đối** ở đây nhỏ ($\approx 7\%$) nhưng **tuyệt đối** lớn.

• Ở giờ đêm, **baseline lại tốt hơn Ridge** ở 7/24 giờ (00:00, 01:00, 02:00, 03:00, 04:00, 22:00,

23:00). Ví dụ rõ nhất là 03:00: baseline 31,14 so với Ridge 142,14. Đây là phát hiện trung thực: ở vùng lưu lượng thấp và ít biến động, bảng trung bình theo giờ × thứ đã gần như tối ưu, còn Ridge bị kéo bởi biến thời tiết.

• Ridge vượt baseline ở **17/24 giờ**, và vượt rõ ở vùng cao điểm — nơi giá trị thực tế tập trung.

!MAE theo giờ và ngày trong tuần trên FINAL TEST 2018

Hình 5 — MAE theo giờ × ngày trên FINAL TEST 2018. Nguồn: `src/evaluate.py`.

10.2 Theo ngày trong tuần

Thứ	n	MAE Ridge	MAE baseline	Lưu lượng thực TB	Bias
Thứ 2	936	347,28	390,36	3.261	+80,41
Thứ 3	933	226,68	239,49	3.542	+33,39
Thứ 4	935	210,36	224,95	3.630	+3,50
Thứ 5	932	230,60	234,97	3.730	-25,98
Thứ 6	935	221,27	236,16	3.772	-58,86
Thứ 7	927	321,27	322,40	2.880	-58,84
Chủ nhật	935	260,93	262,05	2.451	-44,49

Ridge vượt baseline ở **cả 7/7 ngày trong tuần** (dù chỉ nhỉnh ở Thứ 7 và Chủ nhật). Sai số lớn nhất ở **Thứ 2 (347,28)** — ngày làm việc đầu tuần có biến động cao nhất. Ở Thứ 6 lưu lượng thực cao nhất (3.772) nhưng MAE thấp (221,27), bias âm (-58,86).

10.3 Ngày lễ — nơi mô hình yếu rõ rệt

Phân khúc	n mẫu	MAE Ridge	MAE baseline	RMSE	Lưu lượng thực TB	Dự báo TB	Bias
Ngày thường	6.366	239,49	250,58	362,87	3.347	3.335	-11,86
Ngày lễ	167	1.031,44	1.123,43	1.332,59	2.453	2.512	+58,68

- Chênh lệch MAE: **+791,95** — gấp **4,3 lần** ở ngày thường.
- Ở ngày lễ, mô hình **dự báo cao hơn thực tế 58,68 xe/giờ** (thiên lệch dương): mô hình chưa học được việc lưu lượng ngày lễ **tụt mạnh** so với ngày thường, nên dự báo như một ngày làm việc hơi nhẹ.
- Ridge vẫn tốt hơn baseline ở cả hai phân khúc — nhưng **cả hai mô hình đều yếu** ở ngày lễ.

[HẠN CHẾ] Trong FINAL TEST 2018 chỉ có **7 ngày lễ** (167 giờ). Ước lượng trên một mẫu nhỏ như vậy có độ bất định lớn; con số 1.031,44 không nên đọc như một giá trị ổn định.

10.4 Thời tiết

Thời tiết	n mẫu	MAE Ridge	MAE baseline	Bias	Ghi chú
Clear	2.328	245,15	256,64	-23,27	Mẫu đủ
Clouds	1.996	243,39	254,11	-57,30	Mẫu đủ
Drizzle	278	207,16	211,26	+31,50	Mẫu đủ
Rain	992	246,88	254,91	+14,83	Mẫu đủ
Thunderstorm	268	266,76	269,18	+79,74	Mẫu đủ
Mist	1.099	295,41	319,87	+79,46	Mẫu đủ
Haze	272	313,56	332,90	+3,60	Mẫu đủ
Fog	192	536,05	640,17	+315,75	Mẫu đủ — bias dương lớn nhất
Snow	521	524,50	585,36	+238,88	Mẫu đủ
Smoke	2	137,93	88,11	+137,93	Mẫu nhỏ — thận trọng
Squall	0	—	—	—	Không có mẫu — không đánh giá được

Các phân khúc dùng **multi-hot** nên chúng có thể trùng nhau (một giờ vừa mưa vừa tuyết được tính vào cả hai), tổng n có thể vượt 6.533.

Ba phát hiện đáng chú ý:

- **Sương mù (Fog) là phân khúc tệ nhất về bias**: +315,75 xe/giờ, tức mô hình dự báo cao hơn thực tế hơn 315 xe/giờ trong những giờ có sương mù. Có thể vì khi sương mù, tầm nhìn giảm nhưng cách lưu lượng thay đổi không được mô tả bởi 5 biến thời tiết mà mô hình đang có.
- ****Phân khúc Squall có n = 0 → báo cáo ghi rõ "không có mẫu trong FINAL TEST — không đánh giá được"***** thay vì báo số 0. Đây là nguyên tắc: *không có dữ liệu ≠ dự báo bằng 0*.
- **Phân khúc Smoke chỉ có 2 mẫu**, và ở đó baseline còn tốt hơn → artifact gần nhãn **"mẫu nhỏ — thận trọng"**. Số 137,93 không mang thông tin.

!MAE theo nhóm thời tiết trên FINAL TEST 2018

Hình 6 — MAE theo nhóm thời tiết trên FINAL TEST 2018. Nguồn: `src/evaluate.py`.

10.5 Thời tiết cực đoan

Phân khúc	n mẫu	MAE Ridge	MAE baseline	RMSE	Bias
Có tuyết	521	524,50	585,36	784,62	+238,88
Có giông	268	266,76	269,18	409,84	+79,74
Có bão tố (Squall)	0	—	—	—	—
Bất kỳ hiện tượng cực đoan	784	434,08	475,09	675,09	+180,94
Không có hiện tượng cực đoan	5.749	235,96	245,32	367,75	-36,10

Khi có tuyết, MAE **gấp 2,22 lần** so với không có hiện tượng cực đoan; bias **+238,88** nghĩa là mô hình **dự báo cao hơn thực tế gần 239 xe/giờ** trong những giờ có tuyết. Giải thích hợp lý: trong tuyết, nhiều xe không ra đường, nhưng

mô hình chỉ có 1 giờ dữ liệu thời tiết để suy ra điều đó.

10.6 Kết luận phân tích lỗi

Mô hình vượt baseline trên toàn bộ 7/7 ngày trong tuần và 17/24 giờ, nhưng sai số tập trung ở ba nơi, đều có lý do giải thích được:

Nơi	MAE	Cơ chế
Giờ cao điểm 16:00 và 08:00	409 / 376	Lưu lượng lớn → sai số tuyệt đối lớn dù sai số tương đối nhỏ
Ngày lễ	1.031	Hành vi ngày nghỉ lệch mạnh so với ngày thường, mẫu chỉ 7 ngày
Có tuyết / có sương mù	525 / 536	Dữ liệu thời tiết chỉ 1 giờ, không đủ mô tả việc nhiều xe không ra đường

Cả ba đều là hạn chế thật của mô hình, được báo cáo trung thực thay vì giấu bằng cách chỉ trích chỉ số tổng.

11. Thí nghiệm phát triển (2012–2017)

Cảnh báo phân loại. Toàn bộ mục này chạy trong cửa sổ 2012–2017 (34.042 dòng), không chứa dòng nào của năm 2018. Đây là số liệu phát triển phương pháp, không phải kết quả trên FINAL TEST, và không được trộn vào bảng kết luận chính thức ở §9.

11.1 Thí nghiệm 1 — random split so với time split

Cách chia	MAE	RMSE	R²	n	Năm trong tập test
Time split (đúng)	306,48	472,61	0,9422	16.551	2016, 2017
Random split (minh họa)	298,61	481,99	0,9415	5.107	2012...2017

Chênh lệch MAE = -7,87 (random split trông tốt hơn).

[QUYẾT ĐỊNH] Diễn giải có thận trọng, không phóng đại. Hai tập test này khác nhau về thành phần: time split test = 2016–2017 còn nguyên; random split test = mẫu ngẫu nhiên rải rác 2012–2017. Vì vậy chênh lệch không chứng minh được rõ ràng — một phần chênh lệch đến từ việc hai bài toán khác nhau. Vì thế nhóm thiết kế thí nghiệm 1b để đo công bằng.

11.2 Thí nghiệm 1b — kiểm soát rò rỉ (phép so sánh công bằng)

[QUYẾT ĐỊNH] Ba arm dùng CHUNG một tập test (2017-01-01 01:00 → 2017-12-31 23:00, n = 4.357). Chỉ khác nhau ở khoảng thời gian huấn luyện.

Arm	Khoảng train	n train	Cách xa test	MAE	RMSE	R²
A	→ 2015-12-31	17.491	2 năm	270,32	421,30	0,9550
B	→ 2016-12-31	25.329	1 năm	269,32	420,73	0,9551
C	→ 2017-12-31 22:00	29.685	0 năm	262,77	414,02	0,9565

Cải thiện giữa arm xa nhất và gần nhất: 7,55 MAE.

Diễn giải — đây là bằng chứng quan trọng nhất của toàn bài:

Càng đưa dữ liệu sát thời điểm dự báo vào tập huấn luyện, MAE càng giảm — nhưng phần giảm đó không đến từ năng lực mô hình, mà từ việc mô hình đã nhìn thấy "hàng xóm" của chính dòng cần dự báo. Đây chính là rò rỉ mà time split loại bỏ.

Nếu ta chấp nhận con số 262,77 và tuyên bố đó là hiệu năng mô hình, ta đang quảng cáo sai. Vì vậy kết luận trên 2018 phải được công bố từ một mô hình chưa từng thấy năm 2018 — tức arm B chính là cấu hình được đóng băng.

11.3 Thí nghiệm 3 — rolling origin (drift, chỉ out-of-sample)

Thiết kế: cửa sổ mở rộng (expanding window), mọi fold đều ngoài mẫu.

Fold	Năm test	Khoảng test	n	MAE	RMSE	R ²
1	2015	2015-06-11 → 2015-12-31	3.593	325,98	497,93	0,9362
2	2016	2016 cả năm	7.838	343,77	523,66	0,9274
3	2017	2017 cả năm	8.713	272,12	421,46	0,9548

Tổng hợp 20.144 giờ out-of-sample (2015–2017): **MAE = 309,61**.

MAE giảm 53,86 (16,5 %) từ fold 1 đến fold 3. Nhưng kết luận phải là:

Chất lượng được cải thiện, **có thể** do năm gần nhất (2017) dễ hơn, **không nhất thiết** là mô hình tiến bộ. Ba điểm dữ liệu không đủ để phân biệt "mô hình tốt lên" với "năm 2017 dễ hơn".

[QUYẾT ĐỊNH] Tách bạch hai khái niệm mà nhiều báo cáo hay trộn:

- **Performance theo tập** — mô hình tốt hơn không (so sánh ngoài mẫu trên cùng điều kiện);
- **Drift** — dữ liệu có đổi không (kiểm tra phân bố, xem §11.4).

11.4 Thí nghiệm 3b — kiểm tra dịch chuyển phân bố (PSI)

PSI so với năm tham chiếu 2013 (ổn định < 0,1; trung bình 0,1–0,25; mạnh > 0,25):

Biến	2012	2013	2014	2015	2016	2017
traffic_volume	0,0210	0,0000	0,0041	0,0298	0,0345	0,0196
temp	1,1035	0,0000	0,0794	0,7389	0,1619	0,1027
clouds_all	0,3329	0,0000	0,0593	0,6980	0,0715	0,3532

Đọc kết quả:

- Phân bố **mục tiêu** rất ổn định (PSI < 0,035 mọi năm) → hành vi giao thông không dịch chuyển.
- Phân bố **nhệt độ và mây** dịch chuyển mạnh ở 2012 và 2015 (PSI 0,70–1,10) → có thể do mùa và khí hậu, và do **tập 2012 chỉ có 3 tháng** (từ tháng 10) còn 2015 thiếu quý I–II. Đây là hạn chế của phép so sánh PSI khi tập không cùng độ dài.
- PSI của biến đầu vào cao **không** tự động nghĩa mô hình hỏng; nó là tín hiệu cần theo dõi, và ở đây kết hợp với §11.3 cho thấy hiệu năng vẫn ổn định.

!Phân bố thời tiết trên TRAIN

Hình 7 — Phân bố hiện tượng thời tiết, TRAIN. Nguồn: `src/eda.py`. Đây là cơ sở để chọn mã hoá multi-hot thay vì một nhãn đơn.

12. Ứng dụng Web / API

12.1 Nguyên tắc thiết kế — không train-serving skew

Đây là yêu cầu khó nhất khi đưa mô hình ra phục vụ. Nắm rủi ro và cách xử lý:

Rủi ro	Cách xử lý của nhóm	Bằng chứng
Backend tạo feature khác lúc train	Dùng CHUNG hàm <code>src.features.build_features</code>	<code>test_no_train_serving_skew_on_real_rows</code> so từng cột trên dữ liệu thật
Backend lấy <code>is_holiday</code> bằng cách quét dataset	Dùng lịch tất định <code>src/holidays.py</code>	<code>test_holiday_flag_applies_to_whole_day_not_only_midnight</code>
Backend fit lại encoder/imputer/scaler	Không bao giờ — chỉ <code>predict</code> trên pipeline đã đóng băng	<code>test_pipeline_is_not_refit_at_serving</code>
Backend đọc target từ dataset	Không — API chỉ cần <code>models/</code>	<code>test_server_reads_no_target_at_serving</code> (trò data/ vào thư mục rỗng, API vẫn chạy)
Backend tự chọn lại alpha	Không — alpha cứng trong artifact	<code>model-info.serving.tunes_at_serving = false</code>

[QUYẾT ĐỊNH] Ứng dụng **tải artifact lúc khởi động và cache lại**, không nạp lại mỗi request. `src/train.py` là nơi duy nhất được phép ghi vào `models/`.

12.2 Schema thân thiện

Người dùng chỉ cần nhập **thông tin thực sự có ở thời điểm dự báo**:

```
{
  "date_time": "2018-06-15T08:00:00",
  "temperature_celsius": 20.0,
  "rain_1h_mm": 0.0,
  "snow_1h_mm": 0.0,
  "clouds_all": 20,
  "weather": ["Clear"]
}
```

Backend tự suy ra: giờ, thứ, tháng, is_weekend, hour_dow, ****is_holiday (từ lịch — người dùng không**** nhập tay), weather_main_mode, weather_family, weather_severity, 11 cột multi-hot.

- rain_1h_mm / snow_1h_mm **tuỳ chọn**, mặc định 0.
- weather nhận **nhiều hiện tượng cùng lúc** → mã hoá multi-hot, ví dụ
"weather": ["Rain", "Snow", "Thunderstorm"].
- Nhiệt độ nhập **°C**, backend cộng 273,15 → Kelvin.
- state_fair_start_date là **tuỳ chọn**, chỉ dùng khi dự báo nằm ngoài bảng lịch State Fair.

12.3 Ba màn hình

Màn	Đường dẫn	Nội dung
1	/	Tên đề tài, dữ liệu, vị trí I-94 westbound / ATR 301, 2012–2018, mục tiêu, đơn vị xe/giờ, phạm vi sử dụng, giới hạn
2	/du-bao	Form ngày/giờ/nhiệt độ/mưa/tuyết/mây/thời tiết → gọi thật POST /api/traffic-forecast; có trạng thái loading, thành công, lỗi validation, lỗi server
3	/dashboard	Toàn bộ số liệu đánh giá, phân tích lỗi, thí nghiệm, Model Card

Giao diện tiếng Việt, không thư viện ngoài, responsive (đã kiểm tra ở 1440 px và 820 px).

Không có số liệu nào được hard-code trong HTML/JS. Màn 3 lấy mọi con số từ GET /api/dashboard-metrics, và màn 2 lấy danh mục thời tiết hợp lệ từ GET /api/model-info. Có test test_no_final_test_metric_is_hardcoded_in_frontend quét từng file frontend và đối chiếu với giá trị trong artifact để bảo đảm điều này không thoát.

12.4 Validation

Trường	Quy tắc	Lý do chọn mức
date_time	ISO-8601, năm 1900–2200	chỉ bắt lỗi định dạng
temperature_celsius	−70 ... 70 °C	ngoài khoảng này gần như chắc chắn là nhập nhầm Kelvin hoặc °F
rain_1h_mm, snow_1h_mm	≥ 0, ≤ 500	lượng 1 giờ không âm; trần 500 bắt lỗi nhập tổng cả ngày
clouds_all	số nguyên 0 ... 100	đúng định nghĩa %
weather	danh sách không rỗng , chỉ 11 danh mục	sai chính tả (vd clear) cũng bị từ chối, không tự sửa
trường lạ	bị từ chối	extra="forbid" — không bỏ qua âm thầm

Mọi lỗi trả **HTTP 422** với body:

```
{
  "error": "validation_error",
  "message": "Input không hợp lệ: Input should be less than or equal to 100",
  "details": [{ "field": "clouds_all", "message": "...", "type": "less_than_equal" }]
}
```

Server không crash: có exception handler ở mọi tầng; test test_server_survives_a_burst_of_bad_requests gửi liên tiếp 5 payload sai rồi xác nhận request hợp lệ vẫn trả 200.

12.5 Chính sách dự báo của tầng phục vụ (đã đóng băng)

Ridge là hồi quy tuyến tính nên **có thể** trả giá trị âm. Lưu lượng xe không thể âm. Câu hỏi phương pháp: tầng phục vụ có được phép cắt dự báo âm về 0 không?

Đây là quyết định để sinh **test-informed postprocessing**: nếu ta nhìn FINAL TEST 2018 thấy "cắt đi, MAE đẹp hơn" rồi mới quyết định cắt, thì kết luận 2018 mất ý nghĩa. Nhóm xử lý bằng cách **tách quyết định khỏi đo lường**, và đóng băng quyết định trước.

12.5.1 Hai thứ phải phân biệt

	Là gì	Ý nghĩa
RAW MODEL	Ridge(alpha = 0,001, solver lsqr) trả về trực tiếp	Metric của mô hình. Đây là kết luận chính thức, xuất hiện ở §9 và §14.5.
DEPLOYED PREDICTOR	$\max(0, \cdot) \square$ Ridge	Giá trị mà API trả về. Là wrapper phục vụ , KHÔNG phải mô hình khác.

Hai hàng số này **không phải cùng một model metric** và không được gọi chung tên. Mọi con số trong báo cáo nêu là "kết quả của mô hình" đều là số của **RAW MODEL**.

12.5.2 Quy trình: quyết định trước, đo sau

Thứ tự chạy **bắt buộc** của nhóm là: train → experiments → ****freeze_serving_policy → evaluate**** → postprocess_audit. Nói riêng về chính sách phục vụ:

Bước	Script	Dữ liệu dùng	Việc làm
1	src/freeze_serving_policy.py	TRAIN + VALIDATION	Quyết định → ghi models/serving_policy.json
2	src/evaluate.py	FINAL TEST 2018	Mở 2018 ra đánh giá — sau khi policy đã đóng băng
3	src/postprocess_audit.py	FINAL TEST, chạy sau bước 2	Chỉ đo lại hậu quả để báo cáo minh bạch

Nếu đảo bước 1 và 2 (chạy evaluate trước freeze_serving_policy) thì chính sách hậu xử lý sẽ trở thành **test-informed postprocessing**: ta chọn cách hậu xử lý *vì* đã nhìn thấy kết quả 2018, và khi đó FINAL TEST không còn là tập đánh giá độc lập nữa. Chính vì vậy:

- postprocess_audit.py **từ chối chạy** nếu chưa có policy đã đóng băng;
- postprocess_audit.py **từ chối chạy** nếu

artifact tự ghi final_test_used_for_selection khác False;

- có test

test_freeze_script_source_never_reads_final_test kiểm tra ở mức mã nguồn rằng build_policy() chỉ gọi bằng chứng cho train và validation;

- tests/test_report.py::test_pipeline_order_freezes_policy_before_final_test kiểm tra

mọi tài liệu bàn giao đều mô tả đúng thứ tự này.

12.5.3 Quy tắc quyết định (viết trước khi chạy)

Adopt $\max(0, \cdot)$ **khi và chỉ khi** cả ba điều kiện sau đều đúng, tất cả đo trên TRAIN + VALIDATION:

Mã	Điều kiện	Kết quả
D1	$\min(\text{traffic_volume})$ trên TRAIN ≥ 0	PASS (sàn = 0,00)
D2	Mô hình có thực sự trả dự báo thô < 0	PASS (TRAIN 187 dòng, VALIDATION 58 dòng)
D3	MAE sau khi cắt $\leq$ MAE thô trên VALIDATION 2017	PASS (272,12 → 269,55)

Nếu một điều kiện FAIL, script ghi policy = "none" — **không cắt**, và negative prediction được ghi thẳng là limitation. Nhóm đã viết sẵn nhánh này (test_freeze_script_has_fallback_to_no_policy).

12.5.4 Căn cứ (a) — miền giá trị

traffic_volume là số xe đi qua một trạm đo trong một giờ. Số xe **không thể âm**.

- $\min(\text{traffic_volume})$ trên **TRAIN** = **0,00** → sàn miền giá trị đúng là 0.
- min trên VALIDATION = 186,0. (min trên FINAL TEST = 151,0 — **không** dùng để quyết định.)

12.5.5 Căn cứ (b) — VALIDATION 2017

Chỉ số	RAW MODEL	DEPLOYED PREDICTOR ($\max(0, \cdot)$)
Số dự báo thô âm	58 / 8.713 (0,67 %)	—

Chỉ số	RAW MODEL	DEPLOYED PREDICTOR ($\max(0, \cdot)$)
Dự báo thô nhỏ nhất	-790,56	—
MAE	272,12	269,55
RMSE	421,46	416,73
R ²	0,9548	0,9558

Lưu lượng thực trung bình trên các dòng có dự báo âm: **529,91** — sự thật vẫn **đương**, nên cắt về 0 là sửa sai lệch của mô hình, không phải xoá sự thật.

12.5.6 Căn cứ bổ sung — lập luận toán học (không cần dữ liệu)

Với sự thật $y \geq 0$ và sán $b = 0$: $|y - \max(0, \hat{y})| \leq |y - \hat{y}|$ **với mọi giá trị $\hat{y}$** . Chứng minh: nếu $\hat{y} \geq 0$ thì hai vế bằng nhau; nếu $\hat{y} < 0$ thì $|y - 0| = y$ và $|y - \hat{y}| = y - \hat{y} > y$.

Kiểm chứng thực nghiệm trên VALIDATION 2017: sai số tuyệt đối **không tăng ở bất kỳ dòng nào** (`pointwise_abs_error_never_increases = True`), và **đúng 58 dòng** bị thay đổi — bằng đúng số dòng có dự báo âm.

Đây là **phép chiếu đúng theo miền giá trị**, không phải siêu tham số được học từ dữ liệu. Vì vậy nó không vi phạm nguyên tắc "không học gì từ tập test".

12.5.7 Báo cáo tác động trên FINAL TEST (chạy SAU khi đã đóng băng)

Tập	n dự báo thô âm	min thô	MAE — RAW MODEL	MAE — DEPLOYED	RMSE — RAW	RMSE — DEPLOYED
VALIDATION 2017	58 (0,67 %)	-790,56	272,12	269,55	421,46	416,73
FINAL TEST 2018	34 (0,52 %)	-911,35	259,73	257,54	416,78	412,25

Cả 34 dòng ở FINAL TEST đều rơi vào **giờ 0–4 ban đêm**, và **32/34 là ngày lễ**; lưu lượng thực trung bình 572,56 xe/giờ. Điều này cho thấy policy **không phải hình thức**, đồng thời chỉ ra điểm yếu đã nêu ở §10.3: mô hình chưa học được việc lưu lượng đêm ngày lễ gần bằng 0.

12.5.8 Phát biểu trung thực về số liệu

Các số ở §9 (MAE 259,73 · RMSE 416,78 · R² 0,9554) là **RAW MODEL** — kết quả của gói đánh giá đã đóng băng `src/evaluate.py`. Metric của mô hình là số RAW. Số 257,54 là **DEPLOYED PREDICTOR** — giá trị mà API trả về sau khi chiếu về sán. Nó là số của một **wrapper**, không phải của mô hình, và không được trích dẫn như "hiệu năng mô hình". Nhóm **không** chọn policy vì nhìn thấy 34 dự báo âm trên FINAL TEST. Quyết định được chốt trên TRAIN + VALIDATION, theo quy tắc D1–D3, và còn có lập luận toán học độc lập dữ liệu. Nhóm **không** sửa lại gói đánh giá đã đóng băng để khớp API, vì làm vậy tức là dùng kết quả 2018 để điều chỉnh mô hình.

[HẠN CHẾ] Chiếu về sán là **policy**, không phải **học**. Ở một số giờ đêm ngày lễ, lưu lượng thực vẫn vài trăm xe/giờ; mô hình không dự đoán được điều đó, và policy chỉ là giải pháp tạm chứ không phải sửa gốc. Hướng đúng là thêm đặc trưng ngữ cảnh ngày lễ — cần nhiều dữ liệu hơn.

12.6 Thiếu artifact

Nếu `models/ridge_pipeline.joblib` hoặc `model_metadata.json` không có:

- `/health` → **HTTP 503**, `status = "degraded"`, kèm tên file thiếu và lệnh cần chạy;
- `/api/traffic-forecast`, `/api/model-info` → **HTTP 503** với `error = "model_artifact_unavailable"`;
- server **không** sập, và **không** tự huấn luyện (đó là nguyên tắc của dự án).

Test `client_without_artifacts` chỉ vào thư mục `model` rỗng để kiểm chứng.

13. Kiểm thử tự động

****Kết quả: `py -m pytest tests\ -v` → 317 passed, 0 failed.****

File	Số test	Phạm vi
<code>test_data.py</code>	39	collapse trùng, bất biến trong nhóm trùng, quy tắc giá trị vô lý, <code>holiday</code> với <code>keep_default_na=False</code> , đổi chiếu lịch với <code>dataset</code>

File	Số test	Phạm vi
test_features.py	19	Đặc trưng lịch, ngữ nghĩa ngày lễ, time split có assert, random split chỉ để minh họa
test_pipeline.py	20	SimpleImputer nằm trong pipeline và trước scaler, imputer/scaler/encoder fit TRAIN only, xử lý NaN, artifact load được
test_experiments.py	15	Bảo vệ FINAL TEST 2018 (assert_no_final_test_rows), rolling-origin chỉ out-of-sample
test_serving.py	29	°C→K, is_holiday tự tính, multi-weather multi-hot, không train-serving skew , số hữu hạn, cảnh báo phạm vi, chính sách hậu xử lý
test_api.py	81	Route, /health, /api/model-info, dự báo hợp lệ, 12 ca validation sai, web route 200, dashboard lấy số từ artifact, JS hợp lệ
test_serving_policy.py	27	Policy không test-informed, điều kiện D1–D3, phân biệt RAW MODEL vs DEPLOYED PREDICTOR
test_report.py	64	Tài liệu khớp artifact, không bịa số, số test đồng bộ, thử tự pipeline, môi trường tái lập, không lộ đường dẫn cá nhân
Tổng	317	

Con số này không được gõ tay.
tests/test_report.py::test_documented_test_count_matches_real_collection chạy pytest --collect-only trên chính bộ test rồi bắt README, báo cáo, slide, kịch bản demo và câu hỏi vấn đáp phải nói đúng số đó. Thêm hay bớt một test mà quên sửa tài liệu là **test đỏ**, không thể lọt.

13.1 Những test đáng chú ý nhất

Test	Điều nó chứng minh
test_no_train_serving_skew_on_real_rows	Chọn 3 timestamp thật (gồm 1 ngày lễ), dựng feature theo đường dẫn serving, so từng cột với đường dẫn train. Không cột nào lệch.
test_pipeline_is_not_refit_at_serving	Gọi API 8 lần với dữ liệu khác nhau, kiểm tra scaler.mean_ và encoder.categories_ không đổi
test_server_reads_no_target_at_serving	Trở data/ vào thư mục rỗng → API vẫn dự báo được ☐ không đọc dataset
test_holiday_flag_applies_to_whole_day_not_only_midnight	Cờ ngày lễ đúng ở cả giờ 00, 07, 13, 23 (lỗi kinh điển khi chỉ gán cờ ở nửa đêm)
test_no_final_test_metric_is_hardcoded_in_frontend	Quét HTML/JS/CSS, đối chiếu với giá trị artifact
test_frontend_js_is_syntactically_valid	Chặn lỗi cú pháp JS làm trang im lặng (dùng node --check nếu có Node.js)
test_error_segments_include_sample_sizes	Phân khúc n = 0 phải có MAE = null, không được báo 0

13.2 Cấu hình cho người chạy

Ba biến môi trường cho phép trở ứng dụng sang thư mục khác (dùng trong test, không cần cho người dùng):
TRAFFIC_MODELS_DIR, TRAFFIC_REPORTS_DIR, TRAFFIC_DATA_DIR.

14. Model Card

14.1 Tóm tắt mô hình

Tên	ridge_pipeline (phiên bản checkpoint3)
Loại	Hồi quy Ridge (L2) — sklearn.linear_model.Ridge
Hyperparameter	alpha = 0,001, solver = "lsqr"
Tiêu chí chọn alpha	MAE trên VALIDATION 2017
Artifact	models/ridge_pipeline.joblib
Số đặc trưng sau tiền xử lý	217
Target	traffic_volume — lưu lượng, đơn vị xe/giờ
Tạo bởi	src/train.py, seed = 42

14.2 Dữ liệu

Nguồn	Metro Interstate Traffic Volume, UCI ML Repository (CC BY 4.0)
Vị trí	I-94 chiều westbound, trạm ATR 301
Số dòng thô	48.204
Số dòng dùng để mô hình hoá	40.575 (sau khi collapse 7.629 dòng trùng timestamp)
Khoảng thời gian	2012-10-02 09:00 → 2018-09-30 23:00
Đơn vị quan sát	1 giờ tại một trạm đo

14.3 Chia tập

Tập	Khoảng	n
Train (huấn luyện)	2012-10-02 09:00 → 2016-12-31 23:00	25.329
Validation (chọn alpha)	2017-01-01 00:00 → 2017-12-31 23:00	8.713
Final holdout (chỉ đánh giá)	2018-01-01 00:00 → 2018-09-30 23:00	6.533

14.4 Đặc trưng & tiền xử lý

Nhóm	Cột	Tiền xử lý (fit trên TRAIN duy nhất)
Categorical (4)	hour_dow, month, weather_main_mode, weather_family	OneHotEncoder(handle_unknown="ignore", sparse_output=False)
Numeric (5)	temp, rain_1h, snow_1h, clouds_all, weather_severity	SimpleImputer(strategy="median") → StandardScaler()
Binary (12)	is_holiday, wm_clear ... wm_thunderstorm	passthrough

14.5 Số liệu đánh giá (tất cả đều ngoài mẫu)

Tập / mô hình	MAE	RMSE	R ²	n
Validation 2017 — Ridge	272,12	421,46	0,9548	8.713
Validation 2017 — Baseline	278,66	461,00	0,9459	8.713
Final test 2018 — Ridge	259,73	416,78	0,9554	6.533
Final test 2018 — Baseline	272,90	473,13	0,9426	6.533

Không đưa MAE trên tập train vào bảng này: train là **in-sample**, hai dòng trên là **out-of-sample** — trộn chúng là so sánh không cùng đối tượng.

Bốn dòng trên là số của RAW MODEL — Ridge trả về trực tiếp. Đó là metric của *mô hình* và là kết luận chính thức.

Tầng phục vụ áp dụng thêm **DEPLOYED PREDICTOR** = $\max(0, \cdot)$ □ Ridge (chính sách đã đóng băng, xem §12.5). Số của nó được báo ở §12.5.7 và **không được gọi chung tên** với số ở bảng này:

	MAE	RMSE	R ²
RAW MODEL (Ridge) — *metric của mô hình*	259,73	416,78	0,9554
DEPLOYED PREDICTOR ($\max(0, \cdot)$ Ridge) — *wrapper phục vụ*	257,54	412,25	0,9564

14.6 Mục đích sử dụng dự kiến

- Ước lượng sơ bộ lưu lượng theo giờ tại trạm ATR 301 khi chưa có số đo thực tế.
- So sánh kịch bản lưu lượng giữa các ngày có điều kiện thời tiết khác nhau.
- Minh hoạ giá trị của chia tập theo thời gian và đánh giá trung thực trên bài toán chuỗi thời gian thực tế.

14.7 Ngoài phạm vi sử dụng

- Điều khiển giao thông, điều khiển tín hiệu, định tuyến phương tiện.
- **Mọi quyết định an toàn (safety-critical).**
- Suy rộng sang trạm khác, hướng khác, hoặc dùng làm đại diện cho toàn thành phố.
- Dùng như số liệu thống kê chính thức của cơ quan quản lý giao thông.

14.8 Hạn chế

- **Một trạm duy nhất** (ATR 301, I-94 westbound). Kết quả **không đại diện cho toàn thành phố** và không suy rộng được cho trạm hoặc hướng khác.
- **Ngày lễ: MAE = 1.031,44** với $n = 167$ giờ (7 ngày lễ), so với 239,49 ở ngày thường (chênh 791,95). Mô hình dự báo **cao hơn thực tế 58,68 xe/giờ** ở ngày lễ. Mẫu nhỏ nên độ bất định lớn.
- **Thời tiết cực đoan: MAE = 434,08** ($n = 784$) so với 235,96 khi không có ($n = 5.749$) — gấp 1,84 lần. Riêng tuyết: MAE 524,50 (gấp 2,22 lần), bias +238,88. Sương mù còn tệ hơn: MAE 536,05, bias +315,75.
- **Final test chỉ tới 30/09/2018** — không có dữ liệu tháng 10–12/2018.
- **Dữ liệu lịch sử 2012–2018**. Mô hình không cập nhật theo thay đổi hạ tầng, chính sách giao thông, giá nhiên liệu hay hành vi người dùng sau thời điểm này.
- **State Fair có phạm vi năm hữu hạn**. Bảng lịch chỉ có năm **2012–2020** vì ngày khai mạc do bang công bố, không có quy tắc lịch. Ngoài khoảng này API **báo rõ thay vì tự đoán**; người dùng có thể truyền `state_fair_start_date` để tính đúng.
- **Không dùng cho mục đích safety-critical**.
- **Mô hình tuyến tính** — không nắm hiệu ứng phi tuyến phức tạp, và có thể lệch đáng kể ở tình huống chưa từng xuất hiện trong dữ liệu huấn luyện.
- Ở **giờ đêm** (00:00–04:00, 22:00–23:00) baseline lại tốt hơn Ridge (ví dụ 03:00: baseline 31,14 so với Ridge 142,14) → Ridge không phải lựa chọn tối ưu cho mọi khung giờ.
- **Dự báo thô âm** ở 34/6.533 dòng của FINAL TEST (đều giờ 0–4 ban đêm, 32/34 là ngày lễ, thấp nhất -911,35). API chặn về 0 theo policy $\max(0, \cdot)$ và báo cờ `clipped_to_zero`; số liệu ở §14.5 tính trên dự báo **thô** (MAE 259,73), sau khi chặn là 257,54.

14.9 Cách dùng ở thời điểm phục vụ

- Ứng dụng **chỉ nạp** artifact: không huấn luyện, không chọn lại alpha, không fit lại bộ tiền xử lý, không đọc mục tiêu từ dữ liệu.
- Mọi đặc trưng sinh bằng **cùng hàm** `src.features.build_features` với lúc huấn luyện → **không có train-serving skew** (có test đối chiếu từng cột trên dữ liệu thật).
- `is_holiday` tính từ lịch tất định — người dùng không nhập tay.
- Nhiệt độ nhận theo °C, tự quy đổi sang Kelvin.
- Thời tiết mã hoá multi-hot, nhiều hiện tượng cùng lúc.
- **Chính sách phục vụ (đã đóng băng):** $\max(0, \text{dự báo thô})$.
 - Chốt trong `models/serving_policy.json` bởi `src/freeze_serving_policy.py`, ****chỉ dùng TRAIN + VALIDATION; FINAL TEST 2018 không**** tham gia quyết định.
 - Căn cứ: (a) miền giá trị — `traffic_volume` không thể âm, min trên TRAIN = 0,00; (b) VALIDATION 2017 — MAE 272,12 → 269,55, R^2 0,9548 → 0,9558; cộng lập luận toán học $|y - \max(0, \hat{y})| \leq |y - \hat{y}|$ cho mọi $y \geq 0$.
 - API trả kèm `raw_model_output`, `predictor.deployed_prediction` và cờ `clipped_to_zero`.
 - Nếu một trong ba điều kiện D1–D3 không đạt, script tự đặt `policy = "none"` (không cắt) và negative prediction thành limitation.

14.10 Quan hệ với FAIR / minh bạch

Nguyên tắc	Cách thực hiện
Rõ mục đích dùng	§14.6
Rõ ngoài phạm vi	§14.7
Rõ hạn chế	§14.8
Số liệu lấy từ artifact, không gõ tay	toàn bộ; có test kiểm tra frontend không hard-code

Nguyên tắc	Cách thực hiện
Đo lường được bằng máy	317 test, py -m pytest tests\ -v; số test tự đối chiếu bằng pytest --collect-only
Người dùng biết khi nào mô hình không đáng tin	cảnh báo in_dataset_range, state_fair_calendar_unknown trong mọi response

15. Hạn chế và ngoài phạm vi sử dụng

Tóm tắt các điểm cần nói rõ khi bảo vệ:

- **Phạm vi địa lý:** một trạm đo, không đại diện toàn thành phố.
- **Ngày lễ:** MAE gấp 4,3 lần ngày thường, trên mẫu chỉ 7 ngày.
- **Thời tiết cực đoan:** **MAE gấp 1,84 lần** (434,08 so với 235,96); riêng tuyết gấp 2,22 lần với bias +238,88, sương mù bias +315,75.
- **Thời gian:** test 2018 chỉ 9 tháng đầu năm.
- **Tính lịch sử:** dữ liệu 2012–2018, mô hình không tự cập nhật.
- **Lịch State Fair:** giới hạn 2012–2020, ngoài đó hệ thống báo rõ chứ không đoán.
- **An toàn:** không dùng cho mục đích safety-critical.
- **Mô hình tuyến tính:** không nắm hiệu ứng phi tuyến phức tạp.
- **Theo khung giờ:** Ridge không tốt ở giờ đêm — baseline thắng ở 7/24 giờ.
- **Dự báo âm:** 34/6.533 dòng của FINAL TEST có dự báo thô âm (đều giờ 0–4 ban đêm, 32/34 là ngày lễ). API chặn về 0, nhưng đó là policy tạm thời chứ không phải sửa gốc vấn đề.
- **Phụ thuộc mô hình tuyến tính ở giá trị biên:** ngoài phạm vi dữ liệu huấn luyện, dự báo có thể lệch mạnh dù API vẫn cảnh báo.

16. Kết luận và hướng mở rộng

16.1 Kết luận

Nhóm đã hoàn thành đề tài với kết quả:

- **Về phương pháp:** xây dựng được quy trình đánh giá trung thực trên dữ liệu chuỗi thời gian — tiền xử lý tất định, bộ tiền xử lý fit trên TRAIN duy nhất, time split có assert chặn, và FINAL TEST được bảo vệ bằng mã nguồn chứ không chỉ bằng lời hứa.
- **Về kết quả:** Ridge (alpha = 0,001) đạt **MAE 259,73 / RMSE 416,78 / R² 0,9554** trên FINAL TEST 2018, **vượt baseline 13,17 MAE (4,8 %)** trên cùng một tập dữ liệu.
- **Về hiểu biết:** thí nghiệm 1b cho thấy phần cải thiện khi đưa dữ liệu sát thời điểm dự báo vào tập huấn luyện là **rò rỉ**, không phải năng lực mô hình. Đây là bài học trung tâm của đề tài.
- **Về minh bạch:** chỉ ra được mô hình hỏng ở đâu (ngày lễ, tuyết) thay vì chỉ trích chỉ số tổng.
- **Về sản phẩm:** web/API chạy được, chỉ nạp artifact, có validation đầy đủ, 317 test pass.

16.2 Hướng mở rộng

Hướng	Lý do	Cảnh báo về rò rỉ
Thêm đặc trưng lag của traffic_volume	Lưu lượng có tính tự tương quan mạnh theo giờ	Phải shift trước rồi mới drop missing; dùng rolling có phát hiện gốc; tuyệt đối không dùng lag nằm trong tương lai
Mô hình phi tuyến (LightGBM, gradient boosting)	Nhiều khả năng giảm MAE ở giờ đêm và ngày lễ	Phải giữ nguyên time split và quy tắc fit TRAIN only; để rơi vào bẫy chọn mô hình theo test
Dự báo theo mùa với mô hình tuần hoàn (Fourier)	Mô hình hiện tại không có thành phần mùa rõ ràng trong feature	Thành phần tuần hoàn phải là hằng số, không fit từ dữ liệu test
Mô hình riêng cho ngày lễ	MAE ngày lễ cao gấp 4,3 lần	Với chỉ 7 ngày lễ trong 2018, rất dễ overfit — cần dữ liệu nhiều hơn

Hướng	Lý do	Cảnh báo về rò rỉ
Dự báo xác suất (quantile regression)	Khoảng tin cậy rõ hơn cho bài toán lập kế hoạch	Phải chọn trên validation
Hệ thống cập nhật định kỳ	Dữ liệu lịch sử dần cũ	Cần backtest trên nhiều kỳ, không được dùng test cũ làm test mới

16.3 Bài học

Trên cùng một bộ dữ liệu, chỉ cách **chia tập** đã làm MAE chênh nhau gần 8 điểm (§11.1) và 7,55 điểm (§11.2) — lớn ngang với toàn bộ cải thiện mà mô hình đạt được so với baseline (13,17 điểm). Trong bài toán chuỗi thời gian, **cách ta chia tập quan trọng ngang với việc chọn mô hình**.

17. Phụ lục

17.1 Cấu trúc thư mục

```
data/ dữ liệu thô + đã làm sạch + audit + data dictionary
src/ download_data · data · features/holidays/weather · eda · train ·
experiments · evaluate · freeze_serving_policy · postprocess_audit
app/ FastAPI + 3 màn hình web (chỉ load artifact)
models/ ridge_pipeline.joblib + metadata + baseline
reports/ final_report.md (file này) + figures/*.md, *.json, *.png
gồm postprocess_audit.md / .json (kiểm toán hậu xử lý)
docs/ project-log.md (nhật ký dự án), slides-outline.md, demo-script.md,
viva-questions.md
release/ final_report.docx, final_report.pdf, slides.pptx (sinh tự động, đã bàn giao)
tests/ 317 test
```

17.2 Lệnh tái lập toàn bộ (Windows)

```
py -m pip install -r requirements-lock.txt
py src\download_data.py
py src\data.py
py src\eda.py
py src\train.py
py src\experiments.py
py src\freeze_serving_policy.py
py src\evaluate.py
py src\postprocess_audit.py
py -m pip install -r requirements-export.txt
py src\export_docs.py all
py -m pytest tests\ -v
py -m uvicorn app.main:app --reload
```

****Vì sao freeze_serving_policy.py phải đứng trước evaluate.py.**** Chính sách hậu xử lý $\max(0, \cdot)$ được chốt **chỉ từ TRAIN + VALIDATION**. Nếu chạy evaluate.py trước, ta sẽ đã nhìn thấy kết quả 2018 trước khi quyết định có cắt âm hay không — tức **test-informed postprocessing**, làm mất ý nghĩa của FINAL TEST. postprocess_audit.py chỉ đo hậu quả **sau** khi policy đã đóng băng, và từ chối chạy nếu chưa có policy.

Nếu chỉ muốn cài theo khoảng version tương thích thay vì tái lập tuyệt đối, dùng `py -m pip install -r requirements.txt`. Phiên bản thật của môi trường đã sinh artifact nằm trong `models/environment.json`. Seed cố định: 42.

17.3 Danh mục tài liệu tham khảo

Tài liệu	Nội dung
data/README.md	Nguồn, giấy phép, checksum, kết quả audit
data/data_dictionary.md	Mô tả từng biến và các bẫy đã xác minh
reports/figures/data_quality_report.md	Báo cáo chất lượng dữ liệu
reports/figures/eda_train_only.md	EDA chỉ trên TRAIN
reports/figures/experiments_report.md	Thí nghiệm phát triển 2012–2017
reports/figures/evaluation_report.md	FINAL TEST 2018 đầy đủ (24 giờ, 7 ngày, 11 loại thời tiết)
reports/figures/postprocess_audit.md	Kiểm toán chính sách $\max(0, \cdot)$ — số dòng dự báo âm và ảnh hưởng tới metric
docs/project-log.md	Nhật ký dự án theo tuần: người thực hiện, giờ, công việc, kết quả, vấn đề

Tài liệu	Nội dung
docs/slides-outline.md	Dàn ý 11 slide
requirements.txt	Khoảng version tương thích (>=)
requirements-lock.txt	Phiên bản chính xác của môi trường đã sinh artifact (<code>pip freeze</code>)
models/environment.json	Phiên bản Python & thư viện + seed, đọc được bằng máy
requirements-export.txt	Công cụ xuất DOCX/PDF/PPTX
docs/demo-script.md	Kịch bản demo 5–7 phút
docs/viva-questions.md	32 câu hỏi + đáp án

17.4 Nhật ký phát triển

Phản tóm tắt; bảng nhật ký đầy đủ (thời gian · người thực hiện · giờ ước lượng · công việc · kết quả · vấn đề) nằm ở `**docs/project-log.md**`.

Tuần	Việc	Kết quả
1	Brief, data README, data dictionary, kế hoạch baseline	Xác định 7 quy tắc chống rò rỉ trước khi động vào dữ liệu
2	Tải và làm sạch, audit, EDA trên TRAIN, time split	Phát hiện 5.445 nhóm trùng, 10 dòng temp vô lý, 1 dòng rain_1h sentinel
3	Baseline + Ridge pipeline + tune alpha	$\alpha = 0,001$; vượt baseline ngay trên validation
4	Thí nghiệm 1, 1b, 3, 3b (chỉ 2012–2017)	Đo được mức lạc quan do rò rỉ: 7,55 MAE
5	Đóng băng serving policy → FINAL TEST 2018 + phân tích lỗi	Policy chốt trên TRAIN+VAL; MAE 259,73; phát hiện điểm yếu ở ngày lễ và tuyết
6	FastAPI + 3 màn hình + 317 test + tài liệu + bản phát hành	Web/API chạy thật, không train-serving skew

17.5 Tài liệu phát hành

Báo cáo này được soạn bằng Markdown để **kiểm chứng được đối chiếu artifact** — mọi con số đều do `tests/test_report.py` đối chiếu với `models/` và `reports/figures/`. Bản nộp được **sinh tự động từ chính file Markdown đó**, không chép số tay.

```
py -m pip install -r requirements-export.txt
py src\export_docs.py all :: sinh cả 3 định dạng
py src\export_docs.py docx :: hoặc từng định dạng
py src\export_docs.py pdf
py src\export_docs.py pptx
```

Tệp	Nguồn	Công cụ	Quy mô
release/final_report.docx	reports/final_report.md	pandoc (py pandoc-binary)	17 mục, 45 bảng, 7 ảnh nhúng
release/final_report.pdf	reports/final_report.md	reportlab + font Arial	21 trang A4
release/slides.pptx	docs/slides-outline.md	python-pptx	12 slide, 4 ảnh thật

21 trang A4 nằm trong khoảng mục tiêu 15–25 trang. Nếu thiếu một công cụ, script in "BỎ QUA" kèm lý do và **không** tạo file rỗng — để không ai tưởng đã xuất xong.

Các tài liệu đi kèm (giữ nguyên dạng Markdown vì nhóm còn phải điền):

Tệp	Vai trò
docs/project-log.md	nhật ký dự án theo tuần — cần người dùng điền tên + giờ thật
docs/slides-outline.md	dàn ý 11 slide + phụ lục trình chiếu
docs/demo-script.md	kịch bản demo 6 phút 40 giây, 11 bước
docs/viva-questions.md	32 câu hỏi + đáp án, và 9 câu bổ sung

17.6 Nhóm & phân công

□ CẦN NGƯỜI DÙNG ĐIỀN TRƯỚC KHI NỘP Mục này **cố ý để trống có marker**. Nhóm **không** tự bịa tên, không bịa phân công, không bịa số giờ làm. Ba dòng dưới phải do chính thành viên điền bằng thông tin thật: | Trường | Cần điền | | --- | --- | | Thành viên 1 | [TÊN THÀNH VIÊN 1] | | Thành viên 2 | [TÊN THÀNH VIÊN 2] | | Phân công thực tế theo tuần | [PHÂN CÔNG THỰC TẾ] — theo khuôn `docs/project-log.md` | Phần **công việc kỹ thuật theo tuần đã có sẵn** trong `docs/project-log.md`; chỉ cần bổ sung cột *Người thực hiện* và *Giờ ước lượng* bằng dữ liệu thật. **Về lịch sử Git**: hiện lịch sử commit thuộc một tài khoản duy nhất. Nếu đề yêu cầu mỗi thành viên có

phần đóng góp riêng, phần đó **phải do chính thành viên đó tạo** — không đổi tên tác giả, không tạo commit giả cho người khác, không backdate commit.

17.7 Công cụ AI đã sử dụng

Công cụ AI đã sử dụng:

- ChatGPT
- Pi Agent

Mục đích sử dụng:

- hỗ trợ phân tích yêu cầu đề bài
- rà soát phương pháp chống data leakage
- hỗ trợ viết/sửa mã nguồn
- hỗ trợ xây dựng test
- hỗ trợ kiểm tra Web/API
- hỗ trợ chuẩn bị báo cáo, slide và câu hỏi vấn đáp

Cách kiểm chứng lại:

- chạy pipeline trên dataset UCI gốc và đối chiếu SHA256 (`data/README.md`);
- chạy `py -m pytest tests\ -v`;
- đối chiếu mọi metric trong báo cáo với artifact do mã nguồn sinh ra (`models/*.json, reports/figures/*.json`);
- smoke-test FastAPI/Web, kể cả các ca nhập sai;
- đọc lại từng dòng mã nguồn và tài liệu trước khi bảo vệ.

Ranh giới nhóm tự đặt: AI **không** quyết định giá trị nghiệm vụ (quy tắc lịch ngày lễ, định nghĩa danh mục thời tiết, ngưỡng giá trị vô lý) và **không** tạo ra số liệu. Mọi con số trong báo cáo đến từ artifact do mã nguồn sinh ra; `tests/test_report.py` tự động đối chiếu tài liệu với artifact, nên tài liệu không thể lệch số mà không bị test bắt.